

Instituto Tecnológico de Aeronáutica

PO-249

**INTRODUÇÃO ÀS REDES NEURAIS E AOS GRADIENTS MODELOS DE
LINGUAGEM
ATIVIDADE 04**

Aluno: Luiz Eduardo T. C. Cartolano

Prof: Profº Dr. Mauri de Oliveira

São José dos Campos, SP - Brasil

2025

1 Introdução

A análise e previsão de dados complexos são tarefas centrais em diversas áreas do conhecimento, como economia, engenharia, saúde e ciências sociais. Tradicionalmente, modelos estatísticos lineares têm sido amplamente empregados para estimar relações entre variáveis e realizar previsões. No entanto, com o avanço da capacidade computacional e a disponibilidade de grandes volumes de dados, técnicas de aprendizado de máquina, como as redes neurais artificiais, tornaram-se alternativas promissoras para lidar com problemas de modelagem mais complexos e não lineares.

Este artigo tem como objetivo apresentar dois métodos distintos para análise preditiva: a Regressão Linear Multivariável (MRLM) e o Perceptron Multi-Camadas (MLP). Enquanto a MRLM representa um método clássico e amplamente compreendido, o MLP exemplifica uma abordagem moderna de aprendizado profundo, capaz de capturar relações não lineares complexas entre as variáveis.

2 Materiais e Métodos

2.1 Método da Regressão Linear Multivariável

A Regressão Linear Multivariável (MRLM) [2] é uma técnica estatística amplamente utilizada para modelar a relação entre uma variável dependente contínua e um conjunto de variáveis independentes. Enquanto a regressão linear simples considera apenas um preditor, a MRLM permite incorporar múltiplos preditores, possibilitando uma análise mais abrangente e realista de fenômenos complexos.

O modelo geral da MRLM pode ser representado pela seguinte equação:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon \quad (1)$$

onde y é a variável dependente, β_0 é o intercepto, β_i são os coeficientes de regressão associados a cada variável independente x_i , e ϵ representa o termo de erro aleatório. O objetivo da análise é estimar os coeficientes β_i de forma a minimizar a soma dos quadrados dos resíduos $(y_i - \hat{y}_i)^2$, utilizando o método dos Mínimos Quadrados Ordinários (MQO).

Entre as principais suposições do modelo estão: (i) linearidade entre as variáveis independentes e a variável dependente, (ii) independência dos erros, (iii) homocedasticidade (variância constante dos erros) e (iv) normalidade dos resíduos. A violação dessas premissas pode comprometer a validade estatística do modelo, sendo necessário aplicar técnicas de diagnóstico e ajuste quando tais violações são detectadas.

A MRLM é bastante utilizada em diversas áreas do conhecimento, como economia, engenharia e ciências sociais, para fins de previsão e identificação de relações causais.

Sua principal limitação está na suposição de linearidade, o que restringe sua aplicação em fenômenos complexos e não lineares, comuns em contextos reais.

2.2 Perceptron Multi-Camadas - MLP

O Perceptron Multi-Camadas (MLP, do inglês *Multi-Layer Perceptron*) [3] representa uma classe de modelos de redes neurais artificiais projetados para aproximar funções complexas de forma não linear. Diferentemente das redes neurais recorrentes, nas quais há dependências temporais entre os dados, as MLPs são redes *feedforward*, nas quais a informação flui apenas em uma direção, da camada de entrada para a camada de saída, passando por uma ou mais camadas ocultas.

A dinâmica de funcionamento de uma MLP pode ser descrita matematicamente pelas seguintes equações:

$$h^{(l)} = f(W^{(l)}h^{(l-1)} + b^{(l)}), \quad l = 1, \dots, L \quad (2)$$

$$y = g(W^{(L+1)}h^{(L)} + b^{(L+1)}) \quad (3)$$

onde $h^{(l)}$ representa o vetor de ativações na l -ésima camada oculta, $x = h^{(0)}$ é a entrada do modelo, y é a saída, $W^{(l)}$ e $b^{(l)}$ são as matrizes de pesos e vetores de vies ajustados durante o treinamento, f e g são funções de ativação não lineares, como ReLU ou tangente hiperbólica ($\tanh$), e L é o número de camadas ocultas.

O treinamento das MLPs é realizado por meio do algoritmo de retropropagação (*back-propagation*) [1], que calcula os gradientes do erro em relação aos pesos e permite otimizar os parâmetros utilizando métodos como gradiente descendente ou suas variantes. Apesar de não capturarem dependências temporais como as RNNs, as MLPs são altamente eficazes para tarefas de regressão, classificação e aproximação de funções complexas devido à sua capacidade de modelar relações não lineares entre os dados.

As MLPs têm sido aplicadas com sucesso em diversos problemas, incluindo previsão de séries temporais estáticas, reconhecimento de padrões, classificação de imagens e regressão multivariada, destacando-se pela flexibilidade e simplicidade estrutural.

3 Experimento

Com o objetivo de aplicar os métodos apresentados anteriormente, foi desenvolvido um modelo para explicar a variabilidade na margem de lucro anual de associações de poupança e empréstimo. A ideia é incorporar as influências simultâneas de diversas variáveis independentes sobre uma variável dependente.

Neste estudo, buscou-se prever a margem de lucro anual (Y) a partir de duas variáveis explicativas: a receita líquida anual por dólar depositado (X_1) e o número de agências de poupança e empréstimo no respectivo ano (X_2). Espera-se que a receita líquida anual por dólar depositado aumente a margem de lucro anual, enquanto um número maior de agências de poupança e empréstimo possa reduzir a margem de lucro anual devido ao aumento da concorrência.

Assim, a especificação inicial do modelo de regressão populacional adotado é dada por:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon, \quad (4)$$

onde:

- Y : margem de lucro anual,
- X_1 : receita líquida anual por dólar depositado,
- X_2 : número de agências de poupança e empréstimo no ano.

A Tabela 1 apresenta os dados históricos utilizados para o ajuste do modelo, contendo 25 observações (anos) com as respectivas variáveis de interesse.

4 Resultados

4.1 Regressão Linear Múltipla

Os resultados da regressão linear múltipla, considerando a Margem de Lucro como variável dependente e a Receita por Dólar e o Número de Escritórios como variáveis independentes, estão apresentados na Tabela 2.

O modelo apresentou um bom ajuste aos dados, com $R^2 = 0,885$ e R^2 ajustado de 0,875. O teste F global foi significativo ($F = 84,74$, $p < 0,001$), indicando que o conjunto de variáveis explicativas contribui de forma significativa para explicar a Margem de Lucro.

Além disso, os pressupostos clássicos da regressão foram avaliados, conforme apresentado na Tabela 3.

Esses resultados indicam que o modelo ajusta-se bem aos dados e que os pressupostos clássicos da regressão são, em sua maioria, atendidos. A única exceção é a presença de multicolinearidade entre as variáveis independentes, o que recomenda cautela na interpretação isolada dos coeficientes.

Para complementar a análise, a Figura 1 apresenta o plano ajustado pelo modelo de regressão cortando os pontos reais de Margem de Lucro em função da Receita por Dólar e do Número de Escritórios.

Tabela 1: Dados operacionais das associações de poupança e empréstimo.

Ano	Receita por Dólar	Número de Escritórios	Margem de Lucro
1	3,92	7298	0,75
2	3,61	6855	0,71
3	3,66	6935	0,66
4	3,07	6506	0,61
5	3,36	6740	0,69
6	3,11	6402	0,72
7	3,12	6462	0,79
8	3,26	6430	0,74
9	3,42	6369	0,72
10	3,42	6356	0,82
11	3,51	6392	0,81
12	3,66	6798	0,73
13	3,66	6546	0,78
14	3,78	6672	0,84
15	3,82	6890	0,79
16	3,97	7115	0,70
17	4,07	7327	0,68
18	4,27	7542	0,65
19	4,41	7931	0,55
20	4,50	8097	0,63
21	4,70	8468	0,56
22	4,58	8717	0,47
23	4,69	8991	0,51
24	4,71	9179	0,41
25	4,78	9318	0,32

Tabela 2: Coeficientes do modelo de regressão

Variável	Coeficiente	Erro Padrão	p-valor
Constante	1,577	0,073	<0,001
Receita por Dólar	0,198	0,051	0,001
Número de Escritórios	-0,0002	2,92e-05	<0,001

Tabela 3: Resultados dos testes de pressupostos da regressão

Pressuposto	Estatística	p-valor	Conclusão
Norm. dos resíduos	0,962	0,451	Aceita
Homo. (LM)	1,783	0,410	Aceita
Homo. (F)	0,845	0,443	Aceita
Linearidade	0,027	0,871	Aceita
Autocorrelação D-W	1,660	-	Sem autocorrelação
VIF	RD: 8,67; N: 8,67	-	Presente




Figura 1: Plano ajustado pelo modelo de regressão linear múltipla cortando os pontos reais de Margem de Lucro.

4.2 MLP

Os resultados obtidos com o Perceptron Multi-Camadas (MLP) para previsão da Margem de Lucro estão apresentados na Tabela 4. O modelo possui duas camadas ocultas

com 10 e 5 neurônios, utilizando função de ativação ReLU.

Tabela 4: Métricas de desempenho da MLP no conjunto de teste

Métrica	Valor
MSE	0,0423
MAE	0,1775
R^2	-1,6608
MAPE (%)	26,13

A Tabela 5 apresenta uma amostra das predições do modelo comparadas aos valores reais do conjunto de teste.

Tabela 5: Predições da MLP vs valores reais

Valor real	Predição MLP
0,7200	0,8885
0,6800	0,5097
0,7500	0,3781
0,4100	0,4887
0,7300	0,6322

A Figura 2 apresenta a superfície ajustada pelo modelo MLP em comparação com os pontos reais de Margem de Lucro, permitindo uma visualização direta do desempenho do modelo.

5 Discussão

A análise de regressão mostrou que tanto a Receita por Dólar quanto o Número de Escritórios são variáveis estatisticamente significativas na explicação da Margem de Lucro das associações de poupança e empréstimo. O coeficiente positivo da Receita por Dólar indica que aumentos na receita estão associados a margens de lucro maiores, refletindo uma relação direta entre eficiência operacional e desempenho financeiro. Por outro lado, o coeficiente negativo do Número de Escritórios sugere que a expansão da rede física pode reduzir ligeiramente a margem de lucro, possivelmente devido a custos adicionais de operação e manutenção. O modelo apresentou um bom ajuste aos dados ($R^2 = 0,885$) e atendeu à maioria dos pressupostos clássicos da regressão, incluindo normalidade dos resíduos, homocedasticidade, linearidade e ausência de autocorrelação. Entretanto, foi detectada multicolinearidade entre as variáveis independentes, o que indica que os




Figura 2: Superfície ajustada pela MLP em comparação com os pontos reais do conjunto de teste.

coeficientes podem ser instáveis e recomenda cautela na interpretação isolada de cada efeito. De forma geral, os resultados reforçam a importância de equilibrar crescimento de receita e expansão da rede de escritórios para otimizar a Margem de Lucro.

Os resultados obtidos com a MLP indicam que, embora o modelo seja capaz de aprender padrões não lineares complexos, seu desempenho neste conjunto de dados específico apresentou limitações. O valor de R^2 negativo e o MAPE relativamente alto sugerem que o modelo não conseguiu generalizar adequadamente para o conjunto de teste, possivelmente devido ao tamanho reduzido da amostra e à baixa complexidade do problema. Observa-se também que as previsões do modelo podem divergir significativamente dos valores reais em alguns casos, evidenciando que a MLP, apesar de sua flexibilidade, pode ser sensível a variabilidades nos dados quando treinada com poucas observações.

Ao comparar a Regressão Linear Multivariável com a MLP, nota-se que a regressão apresentou um desempenho superior em termos de ajuste e interpretação. Com R^2 elevado e coeficientes interpretáveis, a regressão forneceu uma modelagem consistente da relação entre as variáveis explicativas e a Margem de Lucro, mesmo assumindo uma relação linear. Por outro lado, a MLP, apesar de teoricamente mais poderosa para capturar não linearidades, não conseguiu superar o modelo linear neste conjunto limitado, evidenciando que abordagens complexas nem sempre garantem melhor desempenho quando a quantidade de dados é pequena ou a relação entre as variáveis é próxima da linearidade.

6 Conclusão

Neste estudo, foram comparados dois métodos para análise preditiva da Margem de Lucro: a Regressão Linear Multivariável (MRLM) e o Perceptron Multi-Camadas (MLP). Os resultados mostraram que a MRLM apresentou um desempenho consistente, com alto R^2 e coeficientes interpretáveis, demonstrando sua adequação para conjuntos de dados de pequeno porte e relações lineares entre variáveis.

Por outro lado, a MLP, embora tenha capacidade teórica para modelar relações não lineares complexas, não conseguiu superar a regressão linear neste contexto, apresentando valores de R^2 negativos e maior erro percentual. Esse comportamento evidencia que modelos mais sofisticados não garantem melhor desempenho quando os dados são limitados ou quando a relação entre variáveis é predominantemente linear. Assim, este estudo reforça a importância de escolher o modelo de acordo com as características do problema e do conjunto de dados, equilibrando complexidade do modelo, interpretabilidade e quantidade de informação disponível.

Referências

- [1] Yves Chauvin and David E Rumelhart. *Backpropagation: theory, architectures, and applications*. Psychology press, 2013.
- [2] Nathaniel E Helwig. Multivariate linear regression. *University of Minnesota*, <http://users.stat.umn.edu/~helwig/notes/mvlr-Notes.pdf>, 2017.
- [3] Jaswinder Singh and Rajdeep Banerjee. A study on single and multi-layer perceptron neural network. In *2019 3rd International Conference on Computing Methodologies and Communication (ICCMC)*, pages 35–40. IEEE, 2019.

Anexos

```
1 import json
2
3 import statsmodels.api as sm
4
5 from utils.analyse_regression import analyse_regression
6 from utils.generate_data import generate_regression_data
7 from utils.plot_regression import plot_3d_regression_plane
8
9 if __name__ == "__main__":
10     data = generate_regression_data()
11
12     X = data[['Receita por D lar', 'N mero de Escri t rios']]
13     X = sm.add_constant(X)
14     model = sm.OLS(data['Margem de Lucro'], X)
15     results = model.fit()
16     stats_results = analyse_regression(results, data[['Receita
17         por D lar', 'N mero de Escri t rios']])
18
19     with open("results/project4/stats_summary.txt", "w", encoding
20         ="utf-8") as f:
21         f.write(str(results.summary()))
22
23     with open("results/project4/regression_analysis.json", "w",
24         encoding="utf-8") as f:
25         f.write(json.dumps(stats_results, indent=4))
26
27     plot_3d_regression_plane(data, results, 'Receita por D lar',
28         'N mero de Escri t rios', 'Margem de Lucro',
29         save_path='results/project4/
30             regression_plane.png')
```

Código 1: Script para o MRLM

```
1 import os
2
3 from matplotlib import pyplot as plt
4
5 from utils.generate_data import generate_regression_data
```

```

6 from sklearn.model_selection import train_test_split
7 from sklearn.preprocessing import StandardScaler
8 from sklearn.neural_network import MLPRegressor
9 from sklearn.metrics import mean_squared_error, r2_score,
    mean_absolute_error
10 import numpy as np
11
12 if __name__ == "__main__":
13     # Criar pasta de saída caso não exista
14     output_dir = "results/project4"
15     os.makedirs(output_dir, exist_ok=True)
16     output_file = os.path.join(output_dir, "mlp_results.txt")
17     plot_file = os.path.join(output_dir, "mlp_surface_3d.png")
18
19     # Gerar os dados
20     data = generate_regression_data()
21     X = data[['Receita por Dólar', 'Número de Escritórios']].
        values
22     y = data[['Margem de Lucro']].values.ravel()
23
24     # Dividir treino/teste
25     X_train, X_test, y_train, y_test = train_test_split(X, y,
        test_size=0.2, random_state=42)
26
27     # Normalizar
28     scaler = StandardScaler()
29     X_train_scaled = scaler.fit_transform(X_train)
30     X_test_scaled = scaler.transform(X_test)
31
32     # Criar MLP
33     mlp = MLPRegressor(
34         hidden_layer_sizes=(10, 5),
35         activation='relu',
36         solver='adam',
37         max_iter=1000,
38         random_state=42,
39         verbose=False
40     )
41

```

```

42 # Treinar
43 mlp.fit(X_train_scaled, y_train)
44
45 # Predições
46 y_pred = mlp.predict(X_test_scaled)
47
48 # Métricas
49 mse = mean_squared_error(y_test, y_pred)
50 mae = mean_absolute_error(y_test, y_pred)
51 r2 = r2_score(y_test, y_pred)
52 mape = np.mean(np.abs((y_test - y_pred) / y_test)) * 100
53
54 # Salvar resultados
55 with open(output_file, "w") as f:
56     f.write("MLP Regression Results\n")
57     f.write("=====\n\n")
58     f.write(f"MSE: {mse:.4f}\n")
59     f.write(f"MAE: {mae:.4f}\n")
60     f.write(f"R : {r2:.4f}\n")
61     f.write(f"MAPE (%): {mape:.2f}\n\n")
62
63     f.write("Predições vs Valores Reais (conjunto de teste)
64         :\n")
65     for real, pred in zip(y_test, y_pred):
66         f.write(f"{real:.4f} -> {pred:.4f}\n")
67
68     f.write("\nPesos das camadas:\n")
69     for i, layer_weights in enumerate(mlp.coefs_):
70         f.write(f"Layer {i + 1} weights:\n{layer_weights}\n\n")
71
72     f.write("Bias das camadas:\n")
73     for i, layer_bias in enumerate(mlp.intercepts_):
74         f.write(f"Layer {i + 1} bias:\n{layer_bias}\n\n")
75
76     print(f"Todos os resultados foram salvos em: {output_file}")
77
78 # --- Gerar scatter 3D ---
79 fig = plt.figure(figsize=(10, 7))

```

```

79 ax = fig.add_subplot(111, projection='3d')
80
81 # Plot dos pontos reais
82 ax.scatter(X_test[:, 0], X_test[:, 1], y_test, color='blue',
83            label='Dados reais')
84
85 # Malha para superfície aproximada pela MLP
86 x1_range = np.linspace(X[:, 0].min(), X[:, 0].max(), 20)
87 x2_range = np.linspace(X[:, 1].min(), X[:, 1].max(), 20)
88 X1_grid, X2_grid = np.meshgrid(x1_range, x2_range)
89 X_grid = np.column_stack([X1_grid.ravel(), X2_grid.ravel()])
90 X_grid_scaled = scaler.transform(X_grid)
91 Z_grid = mlp.predict(X_grid_scaled).reshape(X1_grid.shape)
92
93 ax.plot_surface(X1_grid, X2_grid, Z_grid, color='orange',
94                alpha=0.5, label='Superfície MLP')
95
96 ax.set_xlabel('Receita por Dólar')
97 ax.set_ylabel('Número de Escritórios')
98 ax.set_zlabel('Margem de Lucro')
99 ax.set_title('MLP: Superfície Ajustada vs Dados Reais')
100
101 plt.legend()
102 plt.tight_layout()
103 plt.savefig(plot_file, dpi=300)
104 plt.show()
105
106 print(f"Figura 3D salva em: {plot_file}")

```

Código 2: Script para a MLP